

# TEMA 4: ALGORITMOS CLASIFICACIÓN Y REGRESIÓN


↳ SUPERVISADOS:

CLASIFICACIÓN:  $X_{N \times N \times N \times N}$  ,  $W_{N \times 1}$  categorías/discreta  
 matriz datos , vector etiquetas clase

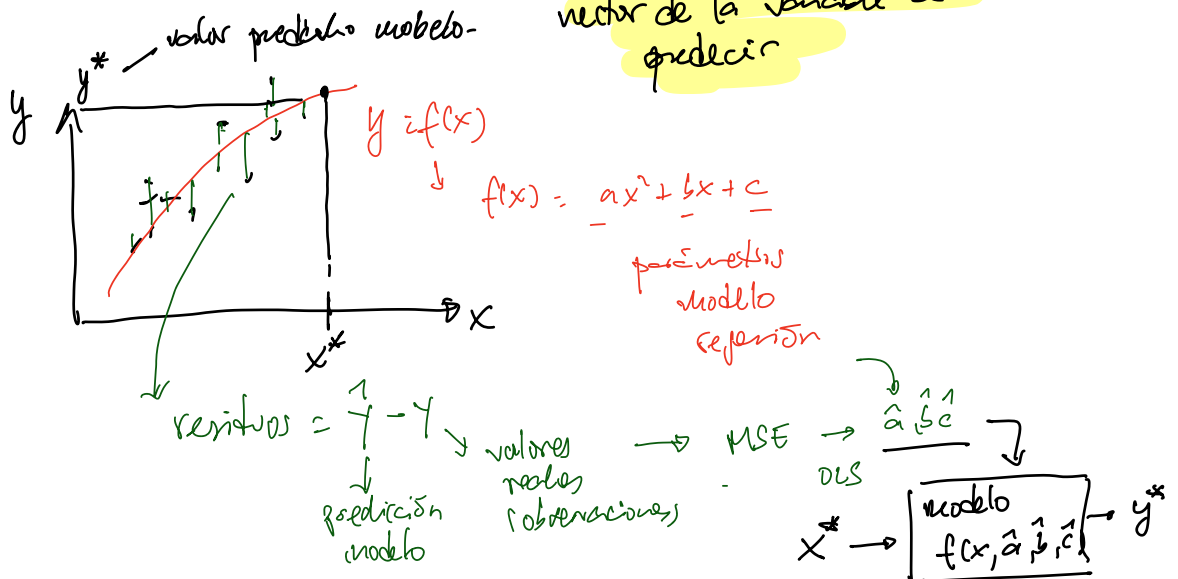
ej: iris - CLASIFICACIÓN  
 4 atributos  
 150 observ.  
 $X_{150 \times 4}$  ,  $W_{150 \times 1}$

$W_i \in \{ 'setosa', 'versicolor', 'virginica' \}$

$\begin{bmatrix} 'setosa' \\ 'versicolor' \\ 'virginica' \\ 'setosa' \end{bmatrix}_{150}$



REGRESIÓN:  $X_{N \times N \times N \times N}$  ,  $y$  continua, reales  
 vector de la variable a predecir



$$\{X, y\} \rightarrow \boxed{\text{Modelo regresión}} \rightarrow y^*_{\text{predicción}}$$

Ex: cars database

mpg	power	weight
○	○	○
○	○	○

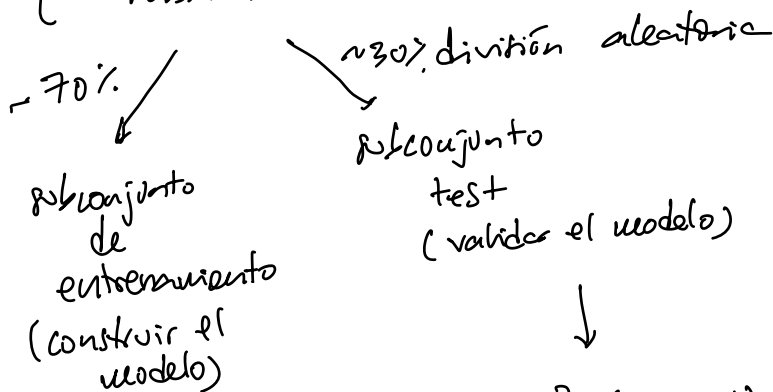
Y                      X

$$X^* = (\text{power}^*, \text{weight}^*) \rightarrow \text{Modelo} \rightarrow \text{mpg}^*$$

## METODOLOGÍA ENTRENAR / INFERENCIA PARAMÉTRICA / AJUSTAR

① train / test

$$\text{DATOS} = \{ X_{\text{NOBS} \times \text{NOVAR}}, w_{\text{NOBS} \times 1} \}$$



$$\{ X_{\text{train}}, w_{\text{train}} \}$$

↓ entrenar

**Modelo ( $\theta^*$ )**

$$\{ X_{\text{test}}, w_{\text{test}} \}$$

**Modelo ( $\theta^*$ )**

↓  $\hat{w}_{\text{test}}$  : predicción para los datos test


1  
 parámetros  
 entrar  $\rightarrow$  modo: probabilístico  
 estimar parámetros  
 geométrico  
 distancias...

COMPARAR  $(\hat{w}_{test}, w_{test})$   
 modelo real

MEDIDAS DE RENDIMIENTO

- matriz confusion
- errores tipo I, II
- medidas: Accuracy, Recall, ...

② Validación cruzada k-veces (k-fold cross-validation) (bootstrapping?)



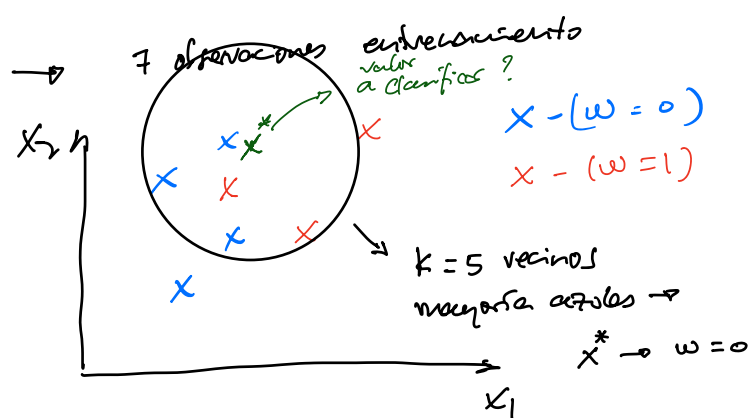
$\Phi_1^* \rightarrow \text{Modelo} \rightarrow \hat{w}_{test}$   
 $\Phi_2^* \dots$

rendimiento promedio

- ① k-primeros vecinos (kNN)
- ② Análisis de discriminantes (probabilístico)
- ③ Árboles de decisión
- ④ Redes Neuronales

① KNN (k-primeros vecinos)

Ex:  $N_{var} = 2$   
 $N_{obs} = 10$



## ② Análisis de discriminantes:


Fórmula de Bayes  
(clasificación)

$$p(w|\vec{x}) = \frac{\overbrace{p(\vec{x}|w)}^{\text{función de verosimilitud Modelo A priori (Prior)}} \cdot \overbrace{p(w)}^{\text{función de verosimilitud Modelo A priori (Prior)}}}{p(\vec{x})}$$

$\downarrow$   
 constante

$\downarrow$   
 densidad  
 posterior  
 (predictiva de  $w$  en función de  $\vec{x}$ )

$p(\vec{x}|w)$ : describe cómo se distribuyen los valores de  $\vec{x}$  en función de la clase a la que pertenecen



$p(w)$ : densidad de probabilidad de las clases (sin datos)

↳ expeto

## Análisis discriminantes

$$g_i(\vec{x}) = \log \underbrace{p(w_i|\vec{x})}_{\text{posterior}} \quad i = 1 \dots N_{\text{CLASES}}$$

↓  
función discriminante

$\vec{x}$  se asigna a la clase que tenga mayor  $g_i(\vec{x})$

$$\hat{w} = \underset{1 \dots N_{\text{CLASES}}}{\text{argmax}} g_i(\vec{x})$$

$$\vec{x} ? \rightarrow \begin{aligned} p(w=0|\vec{x}) &= 0.8 \\ p(w=1|\vec{x}) &= 0.2 \end{aligned} \rightarrow \vec{x} \text{ es de } \begin{pmatrix} \nabla & \nabla \\ 0 & 0 \end{pmatrix} \text{ de } w=0$$

$$p(w|\vec{x}) = \underbrace{p(\vec{x}|w)} \cdot p(w)$$

likelihood :



$$(1) p(\vec{x}|w_i) = N(\vec{x} | \vec{\mu}_i, \Sigma_i)$$

$$(2) p(\vec{x}|w_i) = N(\vec{x} | \vec{\mu}_i, \Sigma) \quad \downarrow \text{igual en todas las clases}$$

(LDA)

$$(3) \text{ (GAUSSIAN NAIVE BAYES) (GNB)}$$

las variables son independientes  $\rightarrow$  hipotesis naive

$$p(\vec{x}|w_i) = \prod_{j=1}^{NVAR} p(x_j|w_i)$$

$$N(x_j | \mu_i, \sigma_i)$$

Gaussian univariada

$$\dots \underbrace{p(\vec{x}|w)} \dots$$

a prior

